

内部能力测评报告

WorkBuddy-v5.5.6 与 MobileWork-0911 DeepInsight 能力对比测评报告

4 个维度 · 19 道任务 · 锁定 Rubric 结果复算与对比

对象 A	WorkBuddy-v5.5.6 / glm-5.2
对象 B	MobileWork-0911 / glm-5.2-w4a8
任务范围	深度研究、财经专家、政企拓客、智慧巡察
报告日期	2026 年 9 月 16 日
保密属性	内部资料

1 执行摘要

本次测评比较 WorkBuddy-v5.5.6（glm-5.2）与 MobileWork-0911（glm-5.2-w4a8）在 4 个维度、19 道任务中的实际交付表现。最终报告只复算和汇总第一阶段已经锁定的任务完成率及五项质量分，不重新评阅原始交付物。总体统计按 19 道题等权；4 个维度等权的质量均分仅作为补充口径。

对象	总体任务完成率	总体质量均分	4 维度等权质量均分	过程首次完成记录
WorkBuddy-v5.5.6	98.15%	4.66	4.56	19/19（100.00%）
MobileWork-0911	85.28%	3.95	4.11	17/19（89.47%）

注：过程“首次完成记录”来自本轮执行过程记录，仅描述是否一次执行形成完成记录；它不等同于按 rubric 计算的任务完成率。

1.1 核心发现

- 总体按 19 题等权计算，WorkBuddy-v5.5.6 的任务完成率为 98.15%、总体质量均分为 4.66；MobileWork-0911 分别为 85.28% 和 3.95，B-A 为 -12.87 个百分点和 -0.71 分。
- 差异不是四个维度同方向。深度研究中两者完成率同为 99.45%，质量均分相差 0.26 分；智慧巡察中 MobileWork-0911 的质量均分为 4.67，高于 WorkBuddy-v5.5.6 的 4.26。
- 财经专家的主要差异来自专业原子项覆盖和结构完整性：WorkBuddy-v5.5.6 完成率 100.00%，MobileWork-0911 为 71.43%；但该维度 MobileWork-0911 的准确率·忠实度均分 3.94，略高于 WorkBuddy-v5.5.6 的 3.75，说明 WorkBuddy 也存在高影响事实证据问题。
- 政企拓客是本轮质量差距最大的维度，B-A 为 -1.31 分。决定性问题集中于源材料边界：MobileWork-0911 多题将源 JSON 未提供的组织关系、预算、认证、外部事实等直接事实化。
- 过程记录显示 WorkBuddy-v5.5.6 的 19 题均一次形成完成记录；MobileWork-0911 有 17 题一次完成，1.6 和 2.3 首次异常后第二次完成。耗时只作为本轮过程描述，不用于推断产品或模型本身计算效率。




图 1 四个维度两对象任务完成率




图 2 四个维度两对象质量均分

2 测评背景、对象与方法

2.1 任务集与对象

本轮任务集由四个业务维度组成，维度内题目数并不相同。总体统计按 19 道题等权，因此题目较多的维度在总体结果中权重更高；报告同时给出“4 个维度质量均分的等权平均”作为补充观察。

维度	题号范围	题数	任务性质
维度一-深度研究	1.1—1.6	6	实时/网页深度研究
维度二-财经专家	2.1—2.5	5	实时上市公司研究
维度三-政企拓客	3.1—3.7	7	基于静态客户 JSON 生成高拜材料
维度四-智慧巡察	4.1	1	七份静态巡察材料综合

2.2 输入与证据边界

- 分数、关键证据、限制和维度结论以 4 份锁定维度总评为权威输入；不重新评分原始交付物。
- 19 道题均记录 rubric SHA-256 和单题 compare-result.md SHA-256。对应原文件未单独提供，因此本报告保留哈希记录，但不宣称已对原文件重新计算哈希。
- 执行过程数据来自本轮 Excel 记录。经用户确认，第二组过程列对应 WorkBuddy-v5.5.6；对象与模型配置统一采用 A=WorkBuddy-v5.5.6/glm-5.2、B=MobileWork-0911/glm-5.2-w4a8。Excel 顶部与该配置冲突的模型备注不作为报告事实来源。
- 历史报告仅作为版式参考，不引入历史任务、分数、排名或结论。

2.3 指标与统计规则

每题任务完成率单独统计；质量采用内容覆盖度、准确率·忠实度、格式合规度、结构完整度、幻觉/自洽性五项指标，均为 0.00—5.00。单题质量均分为五项指标算术平均。维度统计按维度内题目等权；总体统计按 19 道题等权。上层统计使用已经锁定的两位小数单题结果，并以通常四舍五入保留两位小数。

B-A 方向 B-A 固定表示 MobileWork-0911 减 WorkBuddy-v5.5.6。完成率差值使用百分点（pp）；质量差值使用分值。正值只表示对象 B 数值更高，不被解释为脱离任务语境的“总体优胜”。

3 整体量化结果

3.1 四维度统一口径对比

维度	A 完成率	B 完成率	完成率 B-A	A 质量	B 质量	质量 B-A	关键说明
维度一-深度研究	99.45%	99.45%	+0.00pp	4.58	4.32	-0.26	完成率持平；差异主要在实时事实、来源映射和关键数字口径。
维度二-财经专家	100.00%	71.43%	-28.57pp	4.49	3.83	-0.66	A 覆盖/结构更完整；B 准确率略高，但完成与专业链路不足。
维度三-政企拓客	96.31%	81.71%	-14.60pp	4.91	3.60	-1.31	本轮最大质量差距；B 多题出现源外事实或推断事实化。
维度四-智慧巡察	94.08%	94.52%	+0.44pp	4.26	4.67	+0.41	B 准确率优势明显；A 两处跨单位/对象错配触发上限。

总体按 19 题等权：A 完成率 98.15%、质量均分 4.66；B 完成率 85.28%、质量均分 3.95；B-A 分别为 -12.87pp 和 -0.71。四维度等权的质量均分为 4.56 与 4.11，B-A 为 -0.45。

3.2 五项质量指标总体结构




图 3 两对象五项质量指标总体均分

总体差距在五项指标上均存在，但幅度不同。B-A 绝对值较大的项目为幻觉/自治性（-1.14）、准确率·忠实度（-0.92）和结构完整度（-0.72）；格式合规度差距相对较小（-0.25）。这些总体差异主要由财经专家和政企拓客任务拉开，不能用于否定智慧巡察中 MobileWork-0911 的优势。

3.3 单题质量差值分布




图 4 19 道题单题质量均分 B-A

19 道题中，MobileWork-0911 的单题质量均分高于 WorkBuddy-v5.5.6 的有 3 题（1.2、2.2、4.1），1.6 持平，其余 15 题为负差值。最大负差值出现在 3.1（-1.96）和 2.3（-1.85）；最大正差值出现在 4.1（+0.41）。

4 维度一-深度研究

题目范围为 1.1—1.6，共 6 题，重点考察实时网页研究、多源信息交叉验证、事实时点控制、证据映射与深度报告组织。

维度结果 两对象任务完成率均为 99.45%。WorkBuddy-v5.5.6 质量均分 4.58，MobileWork-0911 为 4.32，B-A=-0.26。差距主要来自准确率·忠实度（-0.52）、幻觉/自洽性（-0.42）和格式合规度（-0.31）。

题号/对象	完成率	内容	准确	格式	结构	自洽	质量均分	B-A 质量
1.1 A	100.00%	5.00	3.04	5.00	5.00	4.32	4.47	—
1.1 B	100.00%	4.74	3.75	4.38	5.00	4.32	4.44	-0.03
1.2 A	100.00%	4.79	3.06	4.38	5.00	4.17	4.28	—
1.2 B	100.00%	4.79	4.17	4.38	5.00	4.58	4.58	+0.30
1.3 A	100.00%	5.00	4.69	5.00	5.00	5.00	4.94	—
1.3 B	100.00%	5.00	2.81	4.38	5.00	3.33	4.10	-0.84
1.4 A	100.00%	5.00	4.17	4.38	5.00	5.00	4.71	—
1.4 B	100.00%	5.00	3.06	4.38	5.00	4.17	4.32	-0.39
1.5 A	100.00%	5.00	3.89	5.00	5.00	4.17	4.61	—
1.5 B	100.00%	5.00	1.94	4.38	5.00	3.75	4.01	-0.60
1.6 A	96.67%	4.77	3.44	4.38	5.00	4.58	4.43	—
1.6 B	96.67%	4.77	3.44	4.38	5.00	4.58	4.43	+0.00

4.1 关键差异与证据

- 1.2 人形机器人产业化进程：MobileWork 对国产化率、成本等不确定数据的边界披露更清楚；WorkBuddy 信息密度更高，但若干零部件和资本市场数字缺少一手定位。
- 1.3 全球降息预期下资产配置：WorkBuddy 抓住 2026-09-15 美联储预期已转向加息；MobileWork 对黄金价格和 FOMC 时点判断存在关键偏差，摘要中的黄金价格约 5100 美元/盎司与核实时点市场水平不符。
- 1.5 腾讯 AI 投入与业务韧性：WorkBuddy 的腾讯 Q2 核心财务口径总体更稳；MobileWork 将资本开支 586 亿元、自由现金流-59 亿元写入摘要与主论证，而锁定核验口径分别为 528 亿元和-138 亿元。
- 1.6 文化 IP 与体验消费：两者覆盖一致，行业规模与案例数据都存在二手来源和统计口径风险；代表性国博文创事实可核验，因此最终质量持平。

4.2 维度判断

本维度的差异不在“能否形成长报告”，而在摘要级高影响事实的时点核验、财务口径校验和来源一一映射。WorkBuddy-v5.5.6 在 1.3、1.4、1.5 的实时事实与口径控制更稳，但自身也存在高精度二手数据和来源映射不足；MobileWork-0911 在 1.2 的证据边界披露更稳健，1.6 与 A 完全持平。

改进重点：两对象都应把政策利率、财务口径、市场价格、适航/运营状态等摘要级关键事实绑定到可直接定位的来源。MobileWork-0911 还需要增加截止日前关键时点复核及同名财务指标口径校验。

5 维度二-财经专家

题目范围为 2.1—2.5，共 5 题，覆盖白酒、AI 服务器、保险、动力电池和 AI 芯片等上市公司深度研究，要求同时处理财务、行业、估值、行情、风险和专业变量。

维度结果 WorkBuddy-v5.5.6 完成率 100.00%、质量均分 4.49；MobileWork-0911 完成率 71.43%、质量均分 3.83，B-A=-28.57pp、-0.66。值得注意的是 MobileWork-0911 的准确率·忠实度均分 3.94，略高于 A 的 3.75。

题号/对象	完成率	内容	准确	格式	结构	自洽	质量均分	B-A 质量
2.1 A	100.00%	5.00	4.69	4.38	5.00	5.00	4.81	—
2.1 B	85.71%	4.06	4.69	4.38	4.58	5.00	4.54	-0.27
2.2 A	100.00%	5.00	2.00	4.38	5.00	3.75	4.03	—
2.2 B	71.43%	3.75	4.69	4.38	3.33	4.17	4.06	+0.03
2.3 A	100.00%	5.00	4.38	4.38	5.00	5.00	4.75	—
2.3 B	63.33%	3.00	1.88	3.75	2.14	3.75	2.90	-1.85
2.4 A	100.00%	5.00	4.69	4.38	5.00	4.58	4.73	—
2.4 B	73.33%	3.25	4.06	4.38	3.33	5.00	4.00	-0.73
2.5 A	100.00%	5.00	3.00	4.38	5.00	3.33	4.14	—
2.5 B	63.33%	3.00	4.38	3.75	2.92	4.17	3.64	-0.50

5.1 关键差异与证据

- 2.2 工业富联（601138.SH）：WorkBuddy 研究结构更深，但将谷歌 TPU 订单、Spectrum-X CPO“独家”、Rubin 份额等写成确定业务状态而缺一手确认，触发准确率上限；MobileWork 更谨慎，但资本开支、客户集中、方法和截止日期不完整。
- 2.3 中国平安（601318.SH）：WorkBuddy 基本覆盖保险研究所需的 NBV、COR、银行、ALM、资本/偿付和 PEV；MobileWork 存在 2026H1 集团收入错误、Q1 指标替代 H1 及偿付能力分析缺失。
- 2.4 宁德时代（300750.SZ）：WorkBuddy 在动力/储能、产能、技术与海外链路上更完整，但 9 月 15 日收盘价录入错误；MobileWork 行情值正确，但技术商业化和客户订单的一手证据不足。
- 2.5 寒武纪（688256.SH）：WorkBuddy 覆盖软件生态、客户集中、先进制程和估值框架，但部分芯片性能、量产和客户偏好为产业链口径；MobileWork 财务与估值风险较充分，但客户采购节奏和先进制程供应约束覆盖不足。

5.2 维度判断

WorkBuddy-v5.5.6 的主要优势是专业研究框架和行业特定变量覆盖更完整，但“覆盖深”并不等于事实风险低：工业富联、宁德时代、寒武纪均出现高影响证据或行情字段问题。MobileWork-0911 在部分高风险事实表述上更谨慎，但多题缺少专业必查变量、完整方法说明和三类截止日期，导致完成率、内容覆盖和结构完整度持续受损。

改进重点：A 应对客户/订单/独家供货/芯片性能/量产状态设置一手证据门禁，并对行情基准日进行结构化校验；B 应按题型建立专业必查清单，例如保险的偿付/资本与 PEV、半导体的客户集中/合同阶段/制程约束、动力电池的份额口径与海外合规。

6 维度三-政企拓客

题目范围为 3.1—3.7，共 7 题。每题基于指定客户 JSON 形成谈参高拜材料，事实判断严格以静态源材料为边界，重点考察客户画像、现有合作、项目状态、机会设计、拜访议题和行动闭环。

维度结果 WorkBuddy-v5.5.6 完成率 96.31%、质量均分 4.91；MobileWork-0911 完成率 81.71%、质量均分 3.60，B-A=-14.60pp、-1.31。五项指标中差距最大的是幻觉/自洽性（-2.83）和准确率·忠实度（-2.42）。

题号/对象	完成率	内容	准确	格式	结构	自洽	质量均分	B-A 质量
3.1 A	93.96%	4.85	4.88	5.00	4.75	4.80	4.86	—
3.1 B	51.40%	3.19	2.99	3.96	2.43	1.95	2.90	-1.96
3.2 A	97.20%	4.96	4.90	5.00	4.95	4.78	4.92	—
3.2 B	89.00%	4.85	2.00	4.83	4.43	2.00	3.62	-1.30
3.3 A	97.20%	5.00	4.90	5.00	5.00	4.73	4.93	—
3.3 B	85.80%	4.89	2.00	4.88	4.33	2.00	3.62	-1.31
3.4 A	98.40%	5.00	4.93	5.00	5.00	4.85	4.96	—
3.4 B	88.20%	4.93	2.00	4.94	4.55	2.00	3.68	-1.28
3.5 A	93.80%	4.89	4.86	5.00	4.75	4.73	4.85	—
3.5 B	83.00%	4.85	4.34	4.88	4.43	2.00	4.10	-0.75
3.6 A	96.40%	4.96	4.93	5.00	4.93	4.83	4.93	—
3.6 B	90.80%	4.93	2.00	4.88	4.60	2.00	3.68	-1.25
3.7 A	97.20%	4.96	4.93	5.00	4.95	4.83	4.93	—
3.7 B	83.80%	4.93	2.00	4.88	4.45	1.79	3.61	-1.32

6.1 关键差异与证据

- 3.1 AA 清洁能源与智慧电网集团有限公司谈参高拜报告：WorkBuddy 形成“材料依据—分析判断—拜访议题—行动建议”闭环；MobileWork 未充分梳理本题项目/状态，并引入源 JSON 之外的政策和行业事实，任务完成率和自洽性受影响最大。
- 3.2 BB 生物医药与生命健康科技股份有限公司谈参高拜报告：WorkBuddy 完整列示中标项目、在谈商机、责任和时限；MobileWork 把 FDA 标准平台、ISO27001 认证、CIO 采购决策权等未提供信息写成既成事实。
- 3.4 DD 智慧城市建设与政务数字化投资运营集团谈参高拜报告：WorkBuddy 对项目状态/金额处理准确，并把组织画像等标为推断；MobileWork 将国有独资、独家运营权、特许经营权、采购预算充沛等未提供事实确定化。
- 3.5 XX 数字金融科技股份有限公司谈参高拜报告：WorkBuddy 覆盖金融云、短信、专线、安全和 AI 机会，并对资料缺口给出核实提示；MobileWork 引入具体监管文件、99.999%高可用、日均千万次、零事故等不可追溯事实。
- 3.7 ZZ 智慧远洋物流集团有限公司谈参高拜报告：WorkBuddy 对重点项目状态和人员缺口处理稳健；MobileWork 加入 120 条航线、港口运营权益、总部上海、60%一线人员、年度数字化投入过亿元等未提供事实。

6.2 维度判断

本维度最核心的分界是事实边界执行，而不是报告篇幅。WorkBuddy-v5.5.6 更稳定地把“材料依据、分析判断、建议、待确认”分层，并保持项目自身状态字段；MobileWork-0911 覆盖和分析扩展更积极，但在 6 道题中发现不同形式的源外或不可追溯事实，多题还把组织关系、预算、认证和既有能力状态直接事实化。

改进重点：MobileWork-0911 应建立“源 JSON 白名单事实校验”，任何不在源文件中的企业事实、预算、认证、组织关系和项目状态必须自动降级为判断/待确认；两对象都可将独立待确认清单、关键提问和前中后责任人进一步标准化。

7 维度四-智慧巡察

本维度仅 4.1 一题，要求将七份单位巡察材料综合成跨文稿问题分类、典型/共性问题、整改要求和上级建议。事实核验严格以七份静态 Word 材料为边界。

维度结果 WorkBuddy-v5.5.6 完成率 94.08%、质量均分 4.26；MobileWork-0911 完成率 94.52%、质量均分 4.67，B-A=+0.44pp、+0.41。差异几乎全部来自准确率·忠实度：B-A=+1.87。

题号/对象	完成率	内容	准确	格式	结构	自洽	质量均分	B-A 质量
4.1 A	94.08%	4.86	3.00	4.48	4.35	4.60	4.26	—
4.1 B	94.52%	4.89	4.87	4.48	4.40	4.71	4.67	+0.41

7.1 决定性证据与共同问题

- WorkBuddy-v5.5.6 出现两处明确事实错配：把第五分公司“2025 年二季度各部门绩效系数均按 1 兑现、未履行三重一大”的事实写到第七中心；把“8 个集团客户注销或吊销后仍新开业务”改写成“8 家单位”。按冻结 rubric，准确率·忠实度被限制为 3.00。
- MobileWork-0911 未发现同等级跨单位数字错配，关键数字与单位映射总体稳定，因此准确率·忠实度为 4.87。
- 共同不足：两对象都没有把“典型问题”和“共性问题”做成两个显式层次；多数大类具备“观点—事实—原因”，但具体事实的后果/风险链条并未逐条补齐。

7.2 维度判断

该题说明两对象差异具有明显任务依赖性。与政企拓客相反，MobileWork-0911 在多源静态材料综合中事实映射更稳定；WorkBuddy-v5.5.6 的两处实体/量纲错配直接改变了准确性结论。后续应将“单位 ID—原文段落—数字—问题类型”绑定与量纲原样校验作为长材料综合的自动门禁。

8 执行过程表现

执行过程记录与质量评分分开分析。Excel 中两组“首次用时”经用户确认分别对应 MobileWork-0911 和 WorkBuddy-v5.5.6；记录的时长为首次尝试耗时，不包含第二次重试的完整耗时，因此不能据此计算“成功完成任务的总耗时”。




图 5 本轮执行过程首次/最终形成完成记录

维度	A 首次完成	B 首次完成	A 首次耗时中位数（分钟）	B 首次耗时中位数（分钟）
深度研究	6/6	5/6	12.68	181.93
财经专家	5/5	4/5	10.77	76.33
政企拓客	7/7	7/7	7.75	7.03
智慧巡察	1/1	1/1	11.00	8.62

整体上，WorkBuddy-v5.5.6 的 19 题均一次形成完成记录；MobileWork-0911 为 17/19，一次失败的两题为 1.6 和 2.3，第二次测试均完成。因此按过程记录的最终完成情况，两对象均为 19/19。

首次尝试耗时中位数：WorkBuddy-v5.5.6 为 10.53 分钟，MobileWork-0911 为 76.33 分钟；均值分别约 10.31 和 90.96 分钟。差异主要集中在深度研究和财经专家，而政企拓客、智慧巡察的记录更接近。由于网络、服务负载、产品调度、工具链和结果格式没有做因果控制，这组时长仅用于描述本轮执行记录，不用于判定产品或模型的固有效率。

过程与质量不能混用 例如 MobileWork-0911 的 3.1 在过程记录中“一次完成”，但按 rubric 的任务完成率为 51.40%；反过来，1.6 首次会话失败、第二次完成，但两对象锁定任务完成率均为 96.67%。过程状态与交付质量是两类不同指标。

9 非计分交付观察

以下观察只用于说明交付可获取性和复核便利性，不进入任务完成率或五项质量分。

- 深度研究中 MobileWork 常同时输出 PDF/Markdown/HTML；轻量 HTML 包装页不代表失败，完整内容通常位于 PDF/Markdown。WorkBuddy 多使用 DOCX/HTML，正文组织和目录可读性稳定。
- 财经专家中 MobileWork 多题同时存在大型 HTML 界面壳与 Markdown 正文；同题正文可通过 Markdown 正常读取。WorkBuddy 的 DOCX/HTML 等价导出只按同一成果评价一次。
- 政企拓客中两对象均能形成可阅读成果。WorkBuddy 的“源字段/材料依据”标记更利于人工审计；MobileWork 的 Markdown 结构通常清楚，但事实来源追踪需要加强。
- 智慧巡察中 WorkBuddy 的 DOCX 可正常渲染，MobileWork 的 Markdown 更便于文本检索。题目未指定文件扩展名，因此不以页数、文件数量或视觉精美程度加减分。

10 两对象表现与改进建议

10.1 WorkBuddy-v5.5.6 / glm-5.2

主要优势：在本轮多数任务中，研究/高拜材料的结构闭环、专业变量覆盖和事实—判断分层较稳定，尤其在政企拓客 7 题中保持较高准确性、自治性和任务完成率。深度研究对实时政策与财务口径的时点控制也更稳。

主要短板：高信息密度报告仍会把产业链/媒体二手信息写成确定性事实；财经任务中出现客户/订单状态证据不足、行情基准日错误；智慧巡察出现跨单位事实与量纲错配。

更适合的任务特征：需要严谨结构、专业框架、材料边界与可审计分层的深度研究、财经框架分析和政企高拜材料。对于高影响实时事实和跨单位材料整合，仍需要提交前的结构化事实门禁。

10.2 MobileWork-0911 / glm-5.2-w4a8

主要优势：能够形成结构完整的长报告，在部分任务上对不确定性边界更谨慎；智慧巡察中七份材料的数字与单位映射更稳定，质量均分高于 A；财经工业富联题的高风险事实表述也相对更克制。

主要短板：专业必查变量覆盖和结构闭环不稳定；深度研究存在关键时点/财务口径错误；政企拓客多题把源材料未提供的组织、预算、认证和外部行业事实确定化，导致准确率与幻觉/自治性受较大影响。

更适合的任务特征：需要广覆盖信息整理、长文本组织和多文稿综合的场景；若用于正式财经研究或政企客户材料，应在定稿前增加领域清单和强制事实来源校验。

10.3 分级改进建议

优先级	对象	已证实问题	改进措施	验证方式
P0	MobileWork	1.3/1.5 关键时点或财务口径错误；3.1—3.7 多题源外事实	摘要级关键事实自动复核；政企任务启用源 JSON 白名单，源外企业事实自动降级为“待确认/判断”	复测时检查关键数字、项目状态和组织/预算事实是否逐条可回溯
P0	WorkBuddy	2.2/2.5 二手产业链信息确定化；4.1 跨单位/量纲错配	对客户/订单/芯片性能设置一手证据门禁；长材料建立“单位 ID—段落—数字—问题类型”四元映射与量纲原样校验	对高影响事实和跨单位数字做自动一致性扫描
P1	MobileWork	2.1—2.5 专业原子项和结构闭环缺口	按行业建立必查清单，并固定“行情截止/财务截止/检索截止/方法”字段	统计 T 项/结构项缺失率，目标为不再因通用结构缺项失分
P1	WorkBuddy	1.1/1.2/1.6 来源映射不总是直接	摘要关键数字绑定可直接定位的一手来源；二手估算显式标注	抽查摘要数字，要求 100%有相邻来源或明确“第三方估算”标签
P2	两对象	典型/共性问题、事实后果链和待确认项有时混排	统一标签体系：事实/推断/建议/待确认；巡察中显式拆分典型与共性，并补“后果/风险”	人工复核时可从结论一步定位到题号、来源和事实层级
P2	两对象	过程状态与最终交付质量可能不一致	建立独立的过程状态、文件落盘和质量验收三层门禁	任务结束时分别记录过程完成、规定文件存在、rubric 质量结果

11 有效性边界

- 本次结论只适用于本轮 19 道题、指定产品版本与模型配置，不外推为产品全部能力。
- 总体结果按 19 题等权，政企拓客有 7 题、智慧巡察仅 1 题，因此总体分数受到题目数量结构影响；4 维度等权质量均分作为补充口径。
- 深度研究与财经专家按原执行时点（2026-09-15）评价；后续发生的新公告、新行情不用于倒扣历史交付。政企拓客以各题 JSON 为事实边界，智慧巡察以七份静态 Word 为事实边界。
- 对象 A 与对象 B 同时存在产品和模型配置差异，因此本轮差异不能拆分为“产品因素”或“模型因素”的确定因果。
- 过程耗时来自首次尝试记录；两道 MobileWork 重试任务没有第二次完整耗时，且网络、服务负载、调度与工具等待未受控，因此不据此推断固有效率。
- 维度总评中使用 PDF/DOCX/HTML/Markdown 的实际解析结果；等价导出只计一次。外部事实核验采用关键主张抽查和高风险冲突复核，不等同于对每条外部事实进行全量审计。
- 19 道题的 rubric 和单题结果哈希均有锁定记录，但原文件未单独提供给最终报告阶段，因此没有重新计算哈希。

12 结论

本轮 19 题的任务加权总体结果为：**WorkBuddy-v5.5.6 任务完成率 98.15%、质量均分 4.66；MobileWork-0911 分别为 85.28% 和 3.95。**差异主要由财经专家和政企拓客拉开，其中政企拓客对事实边界、来源可追溯和推断标记最为敏感。

同时，结果不存在跨维度的一致方向。深度研究两对象几乎都完成，质量差异主要来自实时事实核验；财经专家中 WorkBuddy 框架更完整，但自身存在多项高影响事实证据问题；智慧巡察中 MobileWork 的事实映射更稳定并取得更高质量均分。因此，报告不将总体均分解释为所有场景的一致优劣。

从本轮错误模式看，后续最有价值的能力建设不是继续增加报告长度，而是把“高影响事实必须可定位、源外事实必须显式降级、关键数字提交前自动复核、过程完成与质量验收相互独立”做成生成与验收门禁。

附录 A：19 道题结果与证据摘要

以下摘要用于把总体/维度结论回溯到具体题号。分数仍以正文各维度表为准。

1.1 AI Agent 产品对比研究

A：完成率 100.00% / 质量 4.47；B：完成率 100.00% / 质量 4.44；B-A 质量 -0.03。

两者覆盖均完整。WorkBuddy 的故事线与比较矩阵更强，但部分价格、案例和量化锚点主要由二手材料支撑；MobileWork 整体更克制，但部分 WorkBuddy 客户/案例与价格信息仍缺少一手映射。

1.2 人形机器人产业化进程

A：完成率 100.00% / 质量 4.28；B：完成率 100.00% / 质量 4.58；B-A 质量 +0.30。

MobileWork 对国产化率、成本等不确定数据的边界披露更清楚；WorkBuddy 信息密度更高，但若干零部件和资本市场数字缺少一手定位。

1.3 全球降息预期下资产配置

A：完成率 100.00% / 质量 4.94；B：完成率 100.00% / 质量 4.10；B-A 质量 -0.84。

WorkBuddy 抓住 2026-09-15 美联储预期已转向加息；MobileWork 对黄金价格和 FOMC 时点判断存在关键偏差，摘要中的黄金价格约 5100 美元/盎司与核实时点市场水平不符。

1.4 低空经济产业链发展趋势

A：完成率 100.00% / 质量 4.71；B：完成率 100.00% / 质量 4.32；B-A 质量 -0.39。

WorkBuddy 更强调政策、适航与运营状态分级；MobileWork 技术数据更丰富，但部分高精度参数、市场规模和政策节点的一手核验不足。

1.5 腾讯 AI 投入与业务韧性

A：完成率 100.00% / 质量 4.61；B：完成率 100.00% / 质量 4.01；B-A 质量 -0.60。

WorkBuddy 的腾讯 Q2 核心财务口径总体更稳；MobileWork 将资本开支 586 亿元、自由现金流-59 亿元写入摘要与主论证，而锁定核验口径分别为 528 亿元和-138 亿元。

1.6 文化 IP 与体验消费

A：完成率 96.67% / 质量 4.43；B：完成率 96.67% / 质量 4.43；B-A 质量 +0.00。

两者覆盖一致，行业规模与案例数据都存在二手来源和统计口径风险；代表性国博文创事实可核验，因此最终质量持平。

2.1 贵州茅台（600519.SH）

A：完成率 100.00% / 质量 4.81；B：完成率 85.71% / 质量 4.54；B-A 质量 -0.27。

WorkBuddy 在渠道、库存、价格层级和方法结构上更完整；MobileWork 财务与行情分析较全，但渠道“量”证据偏弱，且对白酒消费税公告的“60%孰高原则”表述与公告正文不一致。

2.2 工业富联（601138.SH）

A：完成率 100.00% / 质量 4.03；B：完成率 71.43% / 质量 4.06；B-A 质量 +0.03。

WorkBuddy 研究结构更深，但将谷歌 TPU 订单、Spectrum-X CPO“独家”、Rubin 份额等写成确定业务状态而缺一手确认，触发准确率上限；MobileWork 更谨慎，但资本开支、客户集中、方法和截止日期不完整。

2.3 中国平安（601318.SH）

A：完成率 100.00% / 质量 4.75；B：完成率 63.33% / 质量 2.90；B-A 质量 -1.85。

WorkBuddy 基本覆盖保险研究所需的 NBV、COR、银行、ALM、资本/偿付和 PEV；MobileWork 存在 2026H1 集团收入错误、Q1 指标替代 H1 及偿付能力分析缺失。

2.4 宁德时代（300750.SZ）

A：完成率 100.00% / 质量 4.73；B：完成率 73.33% / 质量 4.00；B-A 质量 -0.73。

WorkBuddy 在动力/储能、产能、技术与海外链路上更完整，但 9 月 15 日收盘价录入错误；MobileWork 行情值正确，但技术商业化和客户订单的一手证据不足。

2.5 寒武纪（688256.SH）

A：完成率 100.00% / 质量 4.14；B：完成率 63.33% / 质量 3.64；B-A 质量 -0.50。

WorkBuddy 覆盖软件生态、客户集中、先进制程和估值框架，但部分芯片性能、量产和客户偏好为产业链口径；MobileWork 财务与估值风险较充分，但客户采购节奏和先进制程供应约束覆盖不足。

3.1 AA 清洁能源与智慧电网集团有限公司谈参高拜报告

A：完成率 93.96% / 质量 4.86；B：完成率 51.40% / 质量 2.90；B-A 质量 -1.96。

WorkBuddy 形成“材料依据—分析判断—拜访议题—行动建议”闭环；MobileWork 未充分梳理本题项目/状态，并引入源 JSON 之外的政策和行业事实，任务完成率和自洽性受影响最大。

3.2 BB 生物医药与生命健康科技股份有限公司谈参高拜报告

A：完成率 97.20% / 质量 4.92；B：完成率 89.00% / 质量 3.62；B-A 质量 -1.30。

WorkBuddy 完整列示中标项目、在谈商机、责任和时限；MobileWork 把 FDA 标准平台、ISO27001 认证、CIO 采购决策权等未提供信息写成既成事实。

3.3 CC 全域智能零售与电商科技集团谈参高拜报告

A: 完成率 97.20% / 质量 4.93; B: 完成率 85.80% / 质量 3.62; B-A 质量 -1.31。

WorkBuddy 对关键人员信息明确标为推演并要求核实；MobileWork 将组织模块职责和“负责全网 12,800 节点”等关系直接事实化。

3.4 DD 智慧城市建设与政务数字化投资运营集团谈参高拜报告

A: 完成率 98.40% / 质量 4.96; B: 完成率 88.20% / 质量 3.68; B-A 质量 -1.28。

WorkBuddy 对项目状态/金额处理准确，并把组织画像等标为推断；MobileWork 将国有独资、独家运营权、特许经营权、采购预算充沛等未提供事实确定化。

3.5 XX 数字金融科技股份有限公司谈参高拜报告

A: 完成率 93.80% / 质量 4.85; B: 完成率 83.00% / 质量 4.10; B-A 质量 -0.75。

WorkBuddy 覆盖金融云、短信、专线、安全和 AI 机会，并对资料缺口给出核实提示；MobileWork 引入具体监管文件、99.999%高可用、日均千万次、零事故等不可追溯事实。

3.6 YY 重工智能装备集团有限公司谈参高拜报告

A: 完成率 96.40% / 质量 4.93; B: 完成率 90.80% / 质量 3.68; B-A 质量 -1.25。

WorkBuddy 准确区分“签约”和“新增”等项目状态；MobileWork 把“年信息化投入预算超过亿元”等未提供预算信息和管理层职责关系写成事实。

3.7 ZZ 智慧远洋物流集团有限公司谈参高拜报告

A: 完成率 97.20% / 质量 4.93; B: 完成率 83.80% / 质量 3.61; B-A 质量 -1.32。

WorkBuddy 对重点项目状态和人员缺口处理稳健；MobileWork 加入 120 条航线、港口运营权益、总部上海、60%一线人员、年度数字化投入过亿元等未提供事实。

4.1 七家单位综合巡察报告

A: 完成率 94.08% / 质量 4.26; B: 完成率 94.52% / 质量 4.67; B-A 质量 +0.41。

两者均完成七份巡察报告综合。WorkBuddy 出现两处明确错配：第五分公司绩效事实被写到第七中心，以及“8 个集团客户”被改写为“8 家单位”，触发准确率 3.00 上限；MobileWork 未发现同等级关键错配。

附录 B：19 道题执行过程记录摘要

首次用时均按原 Excel 记录保留。MobileWork 的 1.6、2.3 只记录首次用时和“第二次测试完成”状态，未提供第二次完整耗时。

号	任务	MobileWork 首次用时	MobileWork 状态	WorkBuddy 首次用时	WorkBuddy 状态
1	AI Agent 产品对比研究	3h 5m 35s	一次完成	16m49s	一次完成
2	人形机器人产业化进程	3h 42m 29s	一次完成	10m32s	一次完成
3	全球降息预期下资产配置	2h 54m 16s	一次完成	6m7s	一次完成
4	低空经济产业链发展趋势	4h 04m 0s	一次完成	18m41s	一次完成
5	腾讯 AI 投入与业务韧性	2h 58m 16s	一次完成	9m31s	一次完成
6	文化 IP 与体验消费	2h 21m 16s	首次会话失败，第二次完成	14m50s	一次完成
7	贵州茅台（600519.SH）	1h 17m 16s	一次完成	5m22s	一次完成
8	工业富联（601138.SH）	1h 16m 20s	一次完成	12m19s	一次完成
9	中国平安（601318.SH）	1h 52m 8s	首次合规服务异常，第二次完成	12m20s	一次完成
10	宁德时代（300750.SZ）	1h 7m 51s	一次完成	10m28s	一次完成
11	寒武纪（688256.SH）	1h 10m 51s	一次完成	10m46s	一次完成
12	AA 清洁能源与智慧电网集团有限公司谈参高拜报告	2h7m39s	一次完成	4m44s	一次完成
13	BB 生物医药与生命健康科技股份有限公司谈参高拜报告	7m2s	一次完成	7m45s	一次完成
14	CC 全域智能零售与电商科技集团谈参高拜报告	6m13s	一次完成	13m33s	一次完成
15	DD 智慧城市建设与政务数字化投资运营集团谈参高拜报告	7m39s	一次完成	11m57s	一次完成
16	XX 数字金融科技股份有限公司谈参高拜报告	9m27s	一次完成	5m32s	一次完成
17	YY 重工智能装备集团有限公司谈参高拜报告	5m17s	一次完成	7m46s	一次完成
18	ZZ 智慧远洋物流集团有限公司谈参高拜报告	6m4s	一次完成	5m47s	一次完成
19	七家单位综合巡察报告	8m37s	一次完成	11m0s	一次完成